

Problemas de Qualidade de Dados em Pipelines de ML: Um Estudo Empírico em Projetos Open-Source

Gabriel Henrique Barbosa — 202601928302

1. Motivação, Objetivo e Perguntas de Pesquisa

Motivação. A adoção de sistemas baseados em aprendizado de máquina (ML) em ambientes de produção tem crescido rapidamente, trazendo desafios inéditos para as equipes de Engenharia de Software. Em particular, a qualidade dos dados utilizados no treinamento de modelos é um fator crítico, frequentemente negligenciado durante o desenvolvimento. Falhas silenciosas causadas por dados inconsistentes, tendenciosos ou desatualizados podem degradar o desempenho de modelos em produção sem qualquer alerta explícito.

Objetivo. Este trabalho investiga como equipes de desenvolvimento detectam e tratam problemas de qualidade de dados em pipelines de ML, com foco em práticas adotadas em projetos open-source.

Perguntas de Pesquisa:

- RQ1: Quais tipos de problemas de qualidade de dados são mais frequentemente reportados em issues de projetos ML open-source?
- RQ2: Quais estratégias de mitigação são adotadas pelas equipes ao detectar esses problemas?

2. Trabalhos Relacionados

- Amershi et al. "Software engineering for machine learning: A case study." ICSE-SEIP, 2019. Identifica desafios práticos no desenvolvimento de sistemas ML na Microsoft, incluindo problemas de qualidade de dados e monitoramento.
- Sculley et al. "Hidden Technical Debt in Machine Learning Systems." NeurIPS, 2015. Discute como dependências de dados não gerenciadas acumulam dívida técnica em sistemas ML de grande escala.
- Hynes et al. "The Data Linter: Lightweight Automated Sanity Checking for ML Data Sets." NIPS Workshop, 2017. Propõe uma ferramenta para detecção automática de problemas comuns em datasets de ML.

3. Metodologia Planejada

Será realizado um estudo empírico baseado em mineração de repositórios (MSR). Selecionaremos um conjunto de repositórios ML open-source hospedados no GitHub (ex.: scikit-learn, Keras, Hugging Face) com base em critérios de popularidade e atividade. As issues e pull requests associadas a problemas de dados serão identificadas por meio de

palavras-chave e classificadas manualmente seguindo um esquema de codificação. A análise quantitativa será utilizada para responder às RQs.

4. Cronograma de Execução

Mês	Atividade
Semana 1	
Semanas 2-4	
Semana 5	
Semana 6	
Semana 7-9	
Semana 10	